

Analisis Serangan *Adversarial Attack* terhadap Model *Machine Learning* pada Klasifikasi Gambar

Muhammad Adam Mirza - 18223015

Program Studi Sistem dan Teknologi Informasi

Institut Teknologi Bandung

Abstrak

Perkembangan *machine learning* telah membuat model klasifikasi gambar banyak digunakan dalam berbagai sistem, seperti pengenalan objek, deteksi wajah, sistem keamanan, dan analisis citra medis. Walaupun model dapat mencapai akurasi tinggi pada data normal, sejumlah penelitian menunjukkan bahwa model tersebut masih dapat dimanipulasi melalui *adversarial attack*. Serangan ini dilakukan dengan menambahkan perturbasi kecil pada gambar *input* sehingga perubahan visualnya sulit dikenali oleh manusia, tetapi dapat menyebabkan model menghasilkan klasifikasi yang salah. Kondisi tersebut menjadi masalah keamanan karena keputusan sistem berbasis *machine learning* dapat dipengaruhi oleh *input* yang telah dimodifikasi secara sengaja. Proposal ini membahas analisis serangan *adversarial attack* terhadap model *machine learning* pada tugas klasifikasi gambar. Fokus pembahasan diarahkan pada konsep *adversarial example*, cara perturbasi memengaruhi proses prediksi model, serta dampaknya terhadap akurasi klasifikasi. Metode serangan yang akan dikaji adalah *Fast Gradient Sign Method (FGSM)* karena metode ini sederhana, banyak digunakan sebagai dasar penelitian *adversarial machine learning*, dan dapat menjelaskan hubungan antara gradien, *loss function*, serta perubahan piksel *input*. Analisis dilakukan dengan membandingkan performa model pada gambar normal dan gambar yang telah diberi perturbasi adversarial. Makalah ini diharapkan dapat menjelaskan bahwa keamanan model *machine learning* tidak hanya ditentukan oleh akurasi pada data uji biasa, tetapi juga oleh ketahanannya terhadap *input* yang sengaja dirancang untuk menyesatkan model. Selain itu, pembahasan juga akan mencakup strategi mitigasi seperti *adversarial training*, pembatasan nilai perturbasi, validasi *input*, dan evaluasi *robustness* model. Dengan demikian, topik ini relevan dengan mata kuliah Keamanan Informasi karena membahas ancaman terhadap integritas sistem berbasis *AI* serta langkah-langkah yang dapat digunakan untuk mengurangi risiko kesalahan klasifikasi akibat serangan adversarial.

Kata kunci: *adversarial attack*, klasifikasi gambar, *machine learning*, *CNN*, keamanan informasi

1. Pendahuluan

1.1 Latar Belakang

Klasifikasi gambar merupakan salah satu penerapan *machine learning* yang banyak digunakan untuk mengenali objek berdasarkan pola visual pada citra. Pada tugas tersebut, model dilatih menggunakan sekumpulan gambar yang telah diberi label, kemudian model diharapkan mampu memprediksi label dari gambar baru. *Convolutional Neural Network (CNN)* menjadi salah satu arsitektur yang sering digunakan karena proses konvolusi dapat menangkap pola lokal pada gambar, seperti tepi, bentuk, dan kombinasi fitur visual lain.

Evaluasi model klasifikasi gambar umumnya dilakukan dengan menghitung akurasi terhadap data uji. Apabila akurasi yang diperoleh tinggi, model sering dianggap sudah bekerja dengan baik. Akan tetapi, akurasi pada data uji biasa tidak selalu menunjukkan bahwa model aman dari manipulasi *input*. Pada konteks keamanan informasi, *input* tidak hanya dapat berasal dari pengguna normal, tetapi juga dapat berasal dari pihak yang sengaja mengubah data agar sistem menghasilkan keputusan yang salah.

Adversarial attack menjadi salah satu ancaman terhadap model *machine learning* karena serangan ini memanfaatkan kelemahan model terhadap perubahan kecil pada *input*. Perubahan tersebut dapat berupa perturbasi pada piksel gambar yang secara visual tampak kecil, tetapi dapat membuat model memprediksi kelas yang berbeda. Pada sistem yang bergantung pada klasifikasi gambar, kesalahan prediksi semacam ini dapat menimbulkan dampak serius, terutama apabila hasil klasifikasi digunakan untuk autentikasi, deteksi objek, pengawasan, atau pengambilan keputusan otomatis.

Penelitian ini difokuskan pada analisis *adversarial attack* menggunakan *Fast Gradient Sign Method (FGSM)*. Metode *FGSM* dipilih karena mekanisme serangannya relatif sederhana dan dapat menunjukkan hubungan langsung antara gradien *loss* terhadap *input* dengan perubahan prediksi model. Dengan menguji beberapa nilai epsilon, pengaruh besar perturbasi terhadap akurasi model dapat diamati secara langsung.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut.

- Bagaimana konsep *adversarial attack* pada model klasifikasi gambar?
- Bagaimana metode *FGSM* digunakan untuk menghasilkan *adversarial example*?
- Bagaimana pengaruh nilai epsilon terhadap akurasi model klasifikasi gambar?

- Strategi mitigasi apa yang dapat diterapkan untuk mengurangi risiko *adversarial attack*?

1.3 Tujuan

Tujuan penelitian ini adalah sebagai berikut.

- Menjelaskan konsep *adversarial attack* dalam konteks keamanan informasi.
- Menjelaskan cara kerja *FGSM* pada model klasifikasi gambar.
- Membandingkan akurasi model pada data normal dan data hasil serangan.
- Mengidentifikasi strategi mitigasi yang dapat digunakan untuk mengurangi risiko *adversarial attack*.

1.4 Batasan Masalah

Pembahasan dalam penelitian ini dibatasi pada *dataset MNIST*, model *CNN* sederhana, dan metode serangan *FGSM*. Serangan yang digunakan bersifat *white-box*, yaitu penyerang diasumsikan memiliki akses terhadap informasi model yang diperlukan untuk menghitung gradien *loss* terhadap *input*. Penelitian ini tidak membahas serangan terhadap sistem nyata, tidak membahas pencurian model, dan tidak membahas serangan fisik terhadap kamera atau sensor.

2. Tinjauan Pustaka

2.1 Klasifikasi Gambar

Klasifikasi gambar adalah proses pemberian label kelas terhadap suatu citra berdasarkan pola visual yang terdapat di dalamnya. Pada model *machine learning*, gambar direpresentasikan sebagai matriks piksel. Setiap nilai piksel menjadi bagian dari *input* yang diproses oleh model untuk menghasilkan prediksi kelas. Pada *dataset MNIST*, setiap gambar berisi angka tulisan tangan berukuran 28 x 28 piksel dalam format *grayscale*, dengan kelas yang terdiri dari angka 0 sampai 9.

Proses klasifikasi dilakukan dengan mempelajari hubungan antara *input* gambar dan label yang benar. Selama pelatihan, bobot model diperbarui agar selisih antara prediksi dan label asli semakin kecil. Selisih tersebut dihitung menggunakan fungsi *loss*. Setelah proses pelatihan selesai, model diuji menggunakan data yang tidak digunakan saat pelatihan untuk mengukur kemampuan generalisasi.

2.2 Convolutional Neural Network

Convolutional Neural Network merupakan arsitektur *neural network* yang dirancang untuk memproses data berbentuk grid, termasuk gambar. *CNN* menggunakan *convolution layer* untuk mengambil fitur lokal dari gambar. Pada tahap awal, fitur yang dipelajari biasanya berupa pola sederhana, seperti garis atau tepi. Pada lapisan berikutnya, fitur tersebut dapat digabungkan menjadi pola yang lebih kompleks.

Pada penelitian ini digunakan model *CNN* sederhana yang terdiri dari dua *convolution layer*, *max pooling*, *dropout*, dan *fully connected layer*. Lapisan konvolusi pertama menerima *input* gambar *MNIST* berukuran 1 x 28 x 28 dan menghasilkan 32 *feature map*. Setelah itu dilakukan *max pooling* sehingga ukuran spasial berkurang. Lapisan konvolusi kedua menghasilkan 64 *feature map* dan kembali diikuti *max pooling*. Hasil akhir kemudian diratakan dan diproses oleh *fully connected layer* untuk menghasilkan prediksi terhadap 10 kelas angka.

2.3 Adversarial Example

Adversarial example adalah *input* yang telah dimodifikasi dengan perturbasi tertentu sehingga model menghasilkan prediksi yang salah. Pada klasifikasi gambar, perturbasi tersebut ditambahkan pada nilai piksel. Perubahan yang diberikan dapat dibuat kecil sehingga gambar masih tampak mirip dengan gambar asli bagi manusia, tetapi representasi numeriknya cukup berbeda bagi model.

Fenomena ini menunjukkan bahwa model dapat mempelajari batas keputusan yang rentan terhadap perubahan kecil. Apabila arah perubahan *input* dipilih secara acak, dampaknya terhadap prediksi belum tentu besar. Namun, apabila perubahan dihitung berdasarkan arah yang menaikkan nilai *loss*, peluang model untuk salah klasifikasi dapat meningkat. Oleh karena itu, *adversarial attack* dapat dipahami sebagai serangan terhadap integritas prediksi model.

2.4 Fast Gradient Sign Method

Fast Gradient Sign Method adalah metode serangan adversarial yang menggunakan gradien fungsi *loss* terhadap *input*. Tujuan *FGSM* adalah mencari arah perubahan piksel yang dapat menaikkan *loss* model. Dengan menaikkan *loss*, prediksi model dibuat semakin menjauh dari label yang benar.

Rumus umum *FGSM* dapat dituliskan sebagai berikut.

$$x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y))$$

Pada rumus tersebut, x adalah *input* asli, x_{adv} adalah *input* adversarial, ϵ adalah besar perturbasi, $J(\theta, x, y)$ adalah fungsi *loss* model dengan parameter θ , *input* x , dan label benar y , sedangkan ∇_x menunjukkan gradien *loss* terhadap *input*. Fungsi *sign* digunakan untuk mengambil arah positif atau negatif dari gradien pada setiap piksel.

Nilai epsilon menentukan besar perubahan yang ditambahkan pada *input*. Jika epsilon bernilai 0, *input* tidak mengalami perubahan. Jika epsilon semakin besar, perturbasi yang diberikan juga semakin kuat. Pada gambar *grayscale* dengan rentang piksel 0 sampai 1, hasil perturbasi perlu dibatasi agar nilai piksel tetap berada pada rentang tersebut.

3. Metodologi

3.1 Dataset

Dataset yang digunakan adalah *MNIST*. *Dataset* ini berisi gambar angka tulisan tangan dengan 10 kelas, yaitu angka 0 sampai 9. Setiap gambar berukuran 28 x 28 piksel dan memiliki satu kanal warna. Pada eksperimen ini digunakan 12.000 sampel data latih dan 2.000 sampel data uji agar proses pelatihan dan pengujian dapat dilakukan dalam waktu yang lebih singkat.

3.2 Model

Model yang digunakan adalah *CNN* sederhana. Arsitektur model terdiri dari dua *convolution layer* dengan ukuran *kernel* 3 x 3, *padding* 1, dan fungsi aktivasi *ReLU*. Lapisan pertama mengubah *input* satu kanal menjadi 32 kanal, sedangkan lapisan kedua mengubah 32 kanal menjadi 64 kanal. Pada setiap *convolution layer* digunakan *max pooling* berukuran 2 x 2 untuk mengurangi ukuran spasial. Setelah proses konvolusi selesai, fitur diratakan dan diproses oleh *fully connected layer* dengan 128 neuron, *dropout* 0,25, dan lapisan keluaran dengan 10 kelas.

Pelatihan model dilakukan menggunakan *optimizer* Adam dengan *learning rate* 0,001. Jumlah *epoch* yang digunakan adalah 1 *epoch*. Meskipun pelatihan dilakukan secara singkat, akurasi bersih yang diperoleh sudah cukup untuk menunjukkan pengaruh serangan *FGSM* terhadap model.

3.3 Skenario Eksperimen

Skenario eksperimen dilakukan melalui beberapa tahap. Pertama, model *CNN* dilatih menggunakan data latih *MNIST*. Kedua, akurasi model dihitung pada data uji normal tanpa perturbasi. Ketiga, data uji dimodifikasi menggunakan *FGSM* dengan nilai epsilon 0,00, 0,05, 0,10, 0,15, 0,20, dan 0,30. Keempat, akurasi model dihitung kembali pada data yang telah diberi perturbasi. Kelima, hasil akurasi dan *attack success rate* dibandingkan untuk melihat pengaruh peningkatan epsilon terhadap performa model.

Serangan dilakukan dengan asumsi *white-box*. Pada skenario ini, informasi model dan gradien *loss* terhadap *input* dapat digunakan untuk menyusun perturbasi. Perturbasi yang dihasilkan kemudian ditambahkan ke gambar asli dan nilai piksel dibatasi pada rentang 0 sampai 1.

3.4 Metrik Evaluasi

Metrik pertama yang digunakan adalah akurasi setelah serangan. Metrik ini menunjukkan proporsi data uji yang masih diklasifikasikan dengan benar setelah *input* diberi perturbasi.

$$\text{Accuracy} = \text{Jumlah prediksi benar} / \text{Jumlah seluruh sampel}$$

Metrik kedua adalah *attack success rate*. Pada penelitian ini, *attack success rate* dihitung sebagai proporsi sampel yang awalnya diklasifikasikan dengan benar, tetapi berubah menjadi salah setelah serangan diberikan.

$$\text{Attack Success Rate} = \frac{\text{Jumlah sampel yang awalnya benar lalu menjadi salah}}{\text{Jumlah sampel yang awalnya benar}}$$

4. Hasil dan Pembahasan

4.1 Hasil Pengujian


Pengujian dilakukan terhadap 2.000 sampel data uji *MNIST*. Berdasarkan hasil evaluasi pada data normal, model memperoleh akurasi bersih sebesar 92,9%. Setelah serangan *FGSM* diterapkan, akurasi model mengalami penurunan seiring peningkatan nilai epsilon. Hasil pengujian ditunjukkan pada Tabel 1.

Tabel 1. Hasil pengujian *FGSM* pada data uji *MNIST*


Epsilon	Total Sampel	Prediksi Benar Setelah Serangan	Akurasi Setelah Serangan	<i>Attack Success Rate</i>
0,00	2.000	1.858	92,90%	0,00%
0,05	2.000	1.726	86,30%	7,10%
0,10	2.000	1.459	72,95%	21,47%
0,15	2.000	1.091	54,55%	41,28%
0,20	2.000	640	32,00%	65,55%
0,30	2.000	55	2,75%	97,04%

(Sumber: Hasil eksperimen penelitian)

Gambar 1. Contoh gambar normal dan gambar hasil perturbasi *FGSM*



Gambar 2. Perubahan akurasi dan *attack success rate* pada beberapa nilai epsilon



4.2 Analisis Pengaruh Epsilon

Berdasarkan Tabel 1, nilai epsilon berpengaruh langsung terhadap penurunan akurasi model. Pada epsilon 0,00, data tidak diberi perturbasi sehingga akurasi yang diperoleh sama dengan akurasi bersih, yaitu 92,90%. Pada epsilon 0,05, akurasi turun menjadi 86,30%. Penurunan ini masih relatif terbatas, tetapi sudah menunjukkan bahwa perubahan kecil pada piksel dapat mempengaruhi sebagian prediksi model.

Penurunan yang lebih besar mulai terlihat pada epsilon 0,10 dan 0,15. Pada epsilon 0,10, akurasi turun menjadi 72,95%, sedangkan pada epsilon 0,15 akurasi turun menjadi 54,55%. Selisih antara epsilon 0,10 dan 0,15 mencapai 18,40 poin persentase. Nilai ini menunjukkan bahwa pada rentang tersebut model mulai kehilangan kemampuan klasifikasi secara cukup besar.

Pada epsilon 0,20, akurasi turun menjadi 32,00%. Pada epsilon 0,30, akurasi hanya tersisa 2,75%. *Attack success rate* pada epsilon 0,30 mencapai 97,04%, yang berarti hampir seluruh sampel yang sebelumnya diklasifikasikan dengan benar berhasil dibuat salah setelah perturbasi ditambahkan. Pola ini menunjukkan bahwa *FGSM* dapat menjadi serangan yang sangat efektif apabila penyerang dapat memilih nilai epsilon yang cukup besar dan memiliki akses terhadap gradien model.

4.3 Interpretasi terhadap *Adversarial Example*

Perubahan gambar akibat *FGSM* tidak dilakukan secara acak. Perturbasi dihitung berdasarkan arah gradien *loss* terhadap *input*. Dengan demikian, setiap piksel diubah menuju arah yang dapat meningkatkan kesalahan model. Meskipun perubahan pada gambar masih dapat tampak kecil pada nilai epsilon tertentu, perubahan tersebut dapat menggeser representasi *input* melewati batas keputusan model.

Pada manusia, angka pada gambar *MNIST* sering masih dapat dikenali meskipun terdapat *noise* ringan. Akan tetapi, model *CNN* membaca gambar sebagai kumpulan nilai numerik. Jika perubahan kecil pada nilai piksel berada pada arah yang sensitif bagi model, hasil prediksi dapat berubah. Hal ini menjelaskan mengapa gambar yang tampak mirip masih dapat menghasilkan label yang berbeda pada model.

Hasil eksperimen juga menunjukkan bahwa akurasi normal tidak cukup untuk menilai keamanan model. Model memperoleh akurasi 92,9% pada data normal, tetapi performanya turun drastis setelah *input* dimodifikasi menggunakan *FGSM*. Dengan kata lain, model dapat bekerja

baik pada data yang tidak diserang, tetapi tetap rentan ketika *input* disusun untuk menaikkan *loss*.

4.4 Hubungan dengan Keamanan Informasi

Dalam keamanan informasi, integritas berkaitan dengan jaminan bahwa data dan hasil pemrosesan tidak berubah secara tidak sah. *Adversarial attack* dapat dikaitkan dengan ancaman terhadap integritas karena *input* dimodifikasi agar sistem menghasilkan keputusan yang keliru. Pada sistem berbasis klasifikasi gambar, keputusan yang salah dapat menyebabkan objek tidak terdeteksi, identitas salah dikenali, atau tindakan otomatis dijalankan berdasarkan informasi yang tidak benar.

Serangan *FGSM* pada penelitian ini dilakukan pada *dataset MNIST* yang sederhana. Namun, pola ancamannya tetap relevan untuk sistem yang lebih besar. Apabila model digunakan pada layanan nyata tanpa pengujian terhadap *input* adversarial, pihak penyerang berpotensi mengeksploitasi kelemahan model melalui manipulasi *input*. Oleh karena itu, evaluasi model perlu mencakup pengujian terhadap *input* normal dan *input* yang sengaja dimodifikasi.

5. Strategi Mitigasi

5.1 *Adversarial Training*

Adversarial training dilakukan dengan memasukkan *adversarial example* ke dalam proses pelatihan. Dengan cara ini, model tidak hanya belajar dari data normal, tetapi juga belajar dari contoh *input* yang telah dimodifikasi. Tujuannya adalah agar batas keputusan model menjadi lebih tahan terhadap perturbasi tertentu. Pada *FGSM*, data latih dapat diberi perturbasi dengan beberapa nilai epsilon, kemudian digunakan kembali untuk melatih model.

5.2 Evaluasi *Robustness*

Evaluasi model sebaiknya tidak hanya dilakukan menggunakan akurasi pada data uji normal. Pengujian tambahan dengan beberapa metode serangan perlu dilakukan agar kelemahan model dapat terlihat lebih awal. Pada penelitian ini, penurunan akurasi terlihat jelas setelah model diuji menggunakan *FGSM*. Jika pengujian hanya dilakukan pada data normal, kelemahan tersebut tidak akan teramati.

5.3 Validasi dan Pembatasan *Input*

Validasi *input* dapat digunakan untuk mendeteksi nilai piksel atau pola *input* yang tidak wajar. Pada sistem nyata, *input* dapat diperiksa sebelum diproses oleh model. Pembatasan rentang nilai, normalisasi, dan pemeriksaan distribusi *input* dapat membantu mengurangi risiko *input* yang sengaja dimanipulasi. Namun, validasi *input* tidak dapat dianggap sebagai perlindungan tunggal karena perturbasi adversarial dapat dibuat tetap berada pada rentang nilai yang terlihat normal.

5.4 Deteksi *Input* Anomali

Deteksi *input* anomali dapat digunakan untuk menandai gambar yang memiliki pola berbeda dari data normal. Metode ini dapat diterapkan sebelum klasifikasi dilakukan atau sebagai lapisan tambahan setelah prediksi model keluar. Apabila *input* ditandai mencurigakan, sistem dapat menolak *input* tersebut, meminta verifikasi tambahan, atau meneruskan data ke pemeriksaan manual.

5.5 Penggunaan Model yang Lebih Tahan

Pemilihan arsitektur dan teknik pelatihan juga dapat mempengaruhi ketahanan model. Model yang dilatih dengan regularisasi, augmentasi data, atau metode pelatihan yang mempertimbangkan perturbasi dapat memiliki ketahanan yang lebih baik dibandingkan model biasa. Meskipun demikian, tidak ada model yang dapat dianggap sepenuhnya bebas dari

adversarial attack. Pengujian berkala tetap diperlukan karena metode serangan dapat berkembang dan menyesuaikan kelemahan model.

6. Penutup

Penelitian ini menunjukkan bahwa model *CNN* sederhana pada *dataset MNIST* dapat mencapai akurasi 92,9% pada data normal, tetapi akurasi tersebut turun setelah serangan *FGSM* diterapkan. Pada epsilon 0,05, akurasi masih berada pada 86,30%, sedangkan pada epsilon 0,30 akurasi turun menjadi 2,75%. *Attack success rate* juga meningkat dari 0,00% pada epsilon 0,00 menjadi 97,04% pada epsilon 0,30.

Hasil tersebut memperlihatkan bahwa peningkatan nilai epsilon membuat perturbasi menjadi lebih kuat dan meningkatkan peluang model menghasilkan klasifikasi yang salah. Dengan demikian, akurasi pada data normal belum cukup untuk menyatakan bahwa model aman. Pada sistem yang menggunakan *machine learning* untuk mengambil keputusan, pengujian terhadap *adversarial example* perlu dilakukan agar risiko terhadap integritas prediksi dapat diketahui.

Mitigasi yang dapat diterapkan meliputi *adversarial training*, evaluasi *robustness*, validasi *input*, deteksi *input* anomali, dan penggunaan model yang lebih tahan terhadap perturbasi. Strategi tersebut tidak menghilangkan risiko sepenuhnya, tetapi dapat mengurangi peluang model dimanipulasi melalui *input* yang sengaja dirancang untuk menyesatkan proses klasifikasi.

Referensi

Goodfellow, I. J., Shlens, J., & Szegedy, C. (2015). *Explaining and Harnessing Adversarial Examples*. *International Conference on Learning Representations (ICLR)*.

Szegedy, C., Zaremba, W., Sutskever, I., Bruna, J., Erhan, D., Goodfellow, I., & Fergus, R. (2014). *Intriguing Properties of Neural Networks*. *International Conference on Learning Representations (ICLR)*.

Madry, A., Makelov, A., Schmidt, L., Tsipras, D., & Vladu, A. (2018). *Towards Deep Learning Models Resistant to Adversarial Attacks*. *International Conference on Learning Representations (ICLR)*.

Lampiran

Link Github: <https://github.com/AdmMRZ/adversarial-attack-image-classification-ii3230>